


$$\text{真正例率} = \frac{TP}{TP + FN}$$


$$\text{假正例率} = \frac{FP}{FP + TN}$$

P-R 曲线: 查准率为  $x$ , 查全率为  $y$

面积和平衡点 ( $P=R$  时  $R$  值)



ROC 曲线: 假正例率为  $x$ , 真正例率为  $y$



F1-score:  $P$  和  $R$  的调和平均

偏差: 算法预测与真实结果偏离程度

欠拟合 = 高偏差

应对: 引入更多特征减弱正则化

方差: 数据扰动对学习性能的影响

高方差 = 过拟合

应对: 增加样本, 加强正则化

SVM: 点  $X$  到超平面  $(w, b)$  距离:  $\frac{|w^T x + b|}{\|w\|}$

$$y(w^T x + b) \geq 1 \rightarrow \text{最小化 } \|w\|$$

由此我们可以得到平面  $w^T X + b = 1$  和  $w^T X + b = -1$  之间的距离为

$$\gamma = \frac{2}{\|w\|}$$

不等式约束下最小化问题

$$L(X, \lambda, \mu) = f(X) + \sum_{j=1}^m \lambda_j h_j(X) + \sum_{k=1}^n \mu_k g_k(X)$$

由不等式约束引入的 KKT 条件 ( $j = 1, 2, \dots, n$ ) 为:

$$\begin{cases} \nabla f + \sum_{j=1}^m \lambda_j \nabla h_j(x) + \sum_{k=1}^n \mu_k \nabla g_k(x) = 0 \\ h_j(x) = 0, j = 1, 2, \dots, m \\ g_k(x) \leq 0, k = 1, 2, \dots, n \\ \mu_k \geq 0 \\ \mu_k g_k(x) = 0. \end{cases}$$

无约束 直接求目标函数得0的点。如果没有解析解的话, 可以使用梯度下降或牛顿方法等迭代的手段来使  $X$  沿负梯度方向逐步逼近极小值点。

$$\min_x f(x) \quad \nabla_x f(x) = 0$$

等式约束: 可以直接应用拉格朗日乘子法去求取最优值

不等式约束: 可以转化为在满足 KKT 约束条件下应用拉格朗日乘子法求解。

拉格朗日求得的并不一定是最优解, 只有在凸优化的情况下, 才能保证得到的是最优解。

对偶 SVM:

$$L(w, b, \beta) = \frac{1}{2} \|w\|^2 + \sum_{i=1}^m \alpha_i (1 - y_i (w^T x_i + b))$$

↓ 对  $w, b$  求偏导 = 0

$$w = \sum_{i=1}^m \alpha_i y_i x_i$$

$$0 = \sum_{i=1}^m \alpha_i y_i$$

$$\sum_{i=1}^m \alpha_i y_i x_i^T x + b$$

**最终模型**

$$f(x) = w^T x + b = \sum_{i=1}^m \alpha_i y_i x_i^T x + b$$

**KKT条件:** (满足此条件才能使用拉格朗日乘子法)

$$\arg \min_{w, b} \frac{1}{2} \|w\|^2$$

s.t.  $y_i(w^T x_i + b) \geq 1, i = 1, 2, \dots, m.$

$$\begin{cases} \alpha_i \geq 0, \\ y_i f(x_i) \geq 1, \\ \alpha_i (y_i f(x_i) - 1) = 0. \end{cases}$$

$y_i f(x_i) > 1 \Rightarrow \alpha_i = 0$  该样本对f(x)没有影响

$y_i f(x_i) - 1 = 0 \Rightarrow$  该样本位于边界, 为支持向量

**支持向量机解的稀疏性:** 训练完成后, 大部分的训练样本都不需保留, 最终模型仅与支持向量有关。

例: 正例点: (3, 3), (4, 3)

负例点: (1, 1)


拉超平面

最优解问题:  $\min(\frac{1}{2} w_1^2 + \frac{1}{2} w_2^2)$

s.t.  $y_i(w^T x_i + b) \geq 1$

$$\Rightarrow \begin{cases} 3w_1 + 3w_2 + b \geq 1 \\ 4w_1 + 3w_2 + b \geq 1 \\ w_1 + w_2 + b \leq -1 \end{cases}$$

$$\Rightarrow \begin{cases} w_1 \geq 0 \\ w_1 + w_2 \geq 1 \\ b \leq -2 \end{cases}$$



故  $w_1 = w_2 = \frac{1}{2}, b = -2$

法二: s.t.  $\Rightarrow$

$$\begin{cases} 1 - 3w_1 - 3w_2 - b \leq 0 \\ 1 - 4w_1 - 3w_2 - b \leq 0 \\ 1 + w_1 + w_2 + b \leq 0 \end{cases} \quad (\text{不等式约束 } g)$$



由不等式的乘子(拉格朗日乘子)  $\mu_i, i = 1, 2, \dots, n$ :

$$\begin{cases} \nabla f + \sum_{i=1}^n \mu_i \nabla g_i(x) + \sum_{j=1}^m \nu_j \nabla h_j(x) = 0 \\ h_j(x) = 0, j = 1, 2, \dots, m \\ \mu_i \geq 0, i = 1, 2, \dots, n \\ \nu_j \geq 0 \\ \mu_i g_i(x) = 0 \end{cases}$$

$$L = \frac{1}{2} (w_1^2 + w_2^2) + \mu_1 (1 - 3w_1 - 3w_2 - b) + \mu_2 (1 - 4w_1 - 3w_2 - b) + \mu_3 (1 + w_1 + w_2 + b)$$

s.t.  $\begin{cases} \mu_1 (1 - 3w_1 - 3w_2 - b) = 0 \\ \mu_2 (1 - 4w_1 - 3w_2 - b) = 0 \\ \mu_3 (1 + w_1 + w_2 + b) = 0 \end{cases}$

$$\begin{cases} \frac{\partial L}{\partial w_1} = w_1 - 3\mu_1 - 4\mu_2 + \mu_3 = 0 \\ \frac{\partial L}{\partial w_2} = w_2 - 3\mu_1 - 3\mu_2 + \mu_3 = 0 \\ \frac{\partial L}{\partial b} = -\mu_1 - \mu_2 + \mu_3 = 0 \end{cases}$$

$\Rightarrow$

$$w_1 = w_2 = \frac{1}{2}, b = -2$$

# 核函数

核函数的基本作用就是接受两个低维空间里的向量, 能够计算出经过某个变换后在高维空间里的向量内积值。

**核支持向量机**

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j - \sum_{i=1}^n \alpha_i$$

s.t.  $\sum_{i=1}^n \alpha_i y_i = 0 \quad (\alpha_i \geq 0, i = 1, 2, \dots, n)$

① 设样本 映射后的向量为 , 划分超平面为

原始问题

$$\min_{w, b} \frac{1}{2} \|w\|^2$$

s.t.  $y_i(w^T \phi(x_i) + b) \geq 1, i = 1, 2, \dots, m.$

对偶问题

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \boxed{\phi(x_i)^T \phi(x_j)} - \sum_{i=1}^m \alpha_i$$

s.t.  $\sum_{i=1}^m \alpha_i y_i = 0, \quad \text{只以内积的形式出现}$

预测

$$f(x) = w^T \phi(x) + b = \sum_{i=1}^m \alpha_i y_i \boxed{\phi(x_i)^T \phi(x)} + b$$

# 软间隔

## 软间隔支持向量机

$$\text{原始问题} \quad \min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i(\mathbf{w}^\top \phi(\mathbf{x}_i) + b))$$

引入松弛变量  $\xi_i \geq 0$ , 可写成

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i$$
$$\text{s.t. } y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \xi_i \geq 0$$

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m l_{0/1}(y_i(\mathbf{w}^\top \phi(\mathbf{x}_i) + b) - 1)$$

其中  $l_{0/1}$  是“0/1损失函数”

$$l_{0/1} = \begin{cases} 1 & z < 0 \\ 0 & \text{otherwise} \end{cases}$$

## 正则化

就是说给损失函数加上一些限制, 通过这种规则去规范他们再接下来的循环迭代中, 不要自我膨胀。

## SVM

### ① 原理:

样本可分 - 硬间隔

.. 近似可分 - 引入松弛变量, 软间隔

.. 不可分 - 核技巧 + 软间隔, 非线性 SVM

### ② 为什么间隔最大化:

鲁棒性好

### ③ 为什么用对偶问题?

1. 易求解

2. 核引入

### ④ 优:

解决高维特征的分类回归问题

解稀稀, 冗余依赖全部数据  
样本可较少

缺:

特征维度  $\gg$  样本数, 表现不好

样本量大时, 映射维度高, 计算量大

核函数难选

缺失敏感

## 决策树

### 基本流程

Algorithm 1 决策树学习基本算法

输入:

- 训练集  $D = \{(x_1, y_1), \dots, (x_m, y_m)\}$ ;
- 属性集  $A = \{a_1, \dots, a_d\}$ .

过程: 函数 TreeGenerate( $D, A$ )

```
1: 生成结点 node;  
2: if  $D$  中样本全属于同一类别  $C$  then  
3:   将 node 标记为  $C$  类叶结点; return  
4: end if  
5: if  $A = \emptyset$  OR  $D$  中样本在  $A$  上取值相同 then  
6:   将 node 标记为叶结点, 其类别标记为  $D$  中样本数最多的类; return  
7: end if  
8: 从  $A$  中选择最优划分属性  $a_*$ ;  
9: for  $a_*$  的每一个值  $a_*^v$  do  
10:  为 node 生成每一个分枝; 令  $D_v$  表示  $D$  中在  $a_*$  上取值为  $a_*^v$  的样本子集;  
11:  if  $D_v$  为空 then  
12:    将分枝结点标记为叶结点, 其类别标记为  $D$  中样本数最多的类; return  
13:  else  
14:    以 TreeGenerate( $D_v, A - \{a_*\}$ ) 为分枝结点  
15:  end if  
16: end for
```

输出: 以 node 为根结点的一棵决策树

(1) 当前结点包含的样本全部属于同一类别

(2) 当前属性集为空, 或所有样本在所有属性上取值相同

(3) 当前结点包含的样本集合为空

$$\text{信息熵 } Ent(D) = - \sum_{k=1}^{|y|} P_k \log P_k$$

$$\text{信息增益 } G(D, a) = Ent(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} Ent(D^v)$$

$$\text{增益率 } G_{-r}(D, a) = \frac{G(D, a)}{- \sum_{v=1}^V \frac{|D^v|}{|D|} \log \frac{|D^v|}{|D|}}$$

优

缺

预剪枝 减小时间开销

欠拟合

后剪枝 减小欠拟合

时间开销大

连续值处理:

① 属性  $a$  取值从小到大排列:

$a^1 a^2 a^3 \dots a^n$

取划分点

$$T_a = \left\{ \frac{a^i + a^{i+1}}{2} \mid 1 \leq i \leq n-1 \right\}$$

② 选取最优划分点

$$\text{Gain}(D, a) = \max_{t \in T_a} \text{Gain}(D, a, t)$$

$$= \max_{t \in T_a} \text{Ent}(D) - \sum_{\lambda \in \{-, +\}} \frac{|D_t^\lambda|}{|D|} \text{Ent}(D_t^\lambda)$$

缺失值处理

让同一样本以不同概率划入不同子结点中

贝叶斯分类器:

$$P(c) \frac{P(x|c)}{\sum_{c'} P(x|c')} = \frac{P(c)}{\sum_{c'} P(c)} \prod_i P(x_i|c)$$

$$P(c|x) = \frac{P(c) \prod_{i=1}^d P(x_i|c)}{P(x)}$$

$$h_{nb}(x) = \arg \max_{c \in Y} P(c) \prod_{i=1}^d P(x_i|c)$$

$$\frac{|D_c|}{|D|}$$

$$\frac{|D_{c,x_i}|}{|D_c|}$$

离散属性  
连续属性

$\mu_{c,i}, \sigma_{c,i}$   
c类样本在第i属性上的均值和方差

$$\frac{1}{\sqrt{2\pi} \sigma_{c,i}} e^{-\frac{(x_i - \mu_{c,i})^2}{2\sigma_{c,i}^2}}$$

避免数据被“抹去”：

拉普拉斯修正： $\hat{P}(c) = \frac{|D_c| + 1}{|D| + N}$

$$\hat{P}(x_i|c) = \frac{|D_{c,x_i}| + 1}{|D_c| + N}$$

(N: D中类别数；

$N_i$ : 第i个属性取值数)